Stručné zhrnutie hlavných zistení

Výskum pasívneho auditu sieťovej bezpečnosti a AI filtrácie nepresností sa za posledné roky významne rozšíril, najmä v oblasti DNS bezpečnosti, detekcie podvodných domén, konfigurácie emailových autentifikačných mechanizmov (SPF, DKIM, DMARC) a využitia strojového učenia na znižovanie falošných poplachov. Moderné metódy často kombinujú pasívnu analýzu DNS záznamov, HTTP bezpečnostných hlavičiek a TLS konfigurácií s pokročilými modelmi strojového učenia, čím zvyšujú presnosť detekcie a umožňujú kalibráciu spoľahlivosti nálezov. Výzvou zostáva robustné rozlišovanie medzi chýbajúcou konfiguráciou a skutočnou zraniteľnosťou, pričom právne požiadavky (NIS2, GDPR) vyžadujú prepojenie technických a procesných kontrol.

Tabuľka najrelevantnejších publikácií

| Názov | Autori, rok | DOI/WOS | Metóda | Dáta | Hlavné výsledky | Obmedzenia | Význam pre LANCE |

|---|---|---|---|---|---|---|---|

| A Redundant Array of Independent Disks (RAID)-Inspired Framework for Robust DNS Security | Masri, R et al., 2025 | [1](https://www.webofscience.com/wos/woscc/full-record/WOS:001580797700001) | RAID-inšpirovaná redundancia DNS | Vlastné experimenty | Zvyšuje odolnosť DNS bez ML, efektívne pri DDoS | Nerieši AI/ML, falošné poplachy | Alternatívny prístup pasívnej ochrany, porovnanie s ML |

| ITransformer_CNN: a malicious DNS detection method with flexible feature extraction | Zhang, WY et al., 2025 | [2] (https://www.webofscience.com/wos/woscc/full-record/WOS:001588384600002) | Transformer + CNN | DNS dáta | Presná detekcia škodlivých DNS, flexibilné extrakcie | Len DNS, absencia iných protokolov | Moderné AI, vhodné pre validáciu AI filtrácie |

| Feature Engineering in Unsupervised DNS Botnet Detectors Based on eXplainable AI | Arkadopoulou, E et al., 2026 | [3](https://www.webofscience.com/wos/woscc/full-record/WOS:001754887400040) | AutoEncoders, SHAP (XAI) | Veľké DNS datasety | Detekcia DGA domén, interpretovateľnosť modelu | Len DNS, absencia email/TLS/HTTP | Vzory pre explainability a kalibráciu spoľahlivosti |

| DCPsolver: Enhancing DNS Cache Poisoning Defenses with Resolver-Based SmartNICs | Kollanur, B et al., 2024 | [4](https://www.webofscience.com/wos/woscc/full-record/WOS:001482964300032) | SmartNIC, real-time detekcia DCP | Dataset DCP útokov | Efektívna detekcia DCP v reálnom čase | Zamerané na DCP, bez AI | Relevantné na porovnanie pasívnej/aktívnej analýzy |

| Too Open to be Secure: An Evaluation of OpenNIC DNS Services and Domains | Yang, DS et al., 2026 | [5](https://www.webofscience.com/wos/woscc/full-record/WOS:001882330100023) | ML klasifikácia | 300 mil+ DNS dotazov | Polovica OpenNIC prevádzky je škodlivá, vysoká presnosť | Len OpenNIC, absencia email/TLS | Dôkaz o prínose ML pri pasívnej analýze DNS |

| P4DME: DNS Threat Mitigation with P4 In-Network Machine Learning Offload | Vanerio, J et al., 2023 | [6](https://www.webofscience.com/wos/woscc/full-record/WOS:001148155800008) | ML + P4 switch | Simulácie | 99,9% offload, ~5% zvýšenie FN | Zamerané na infraštruktúru | Príklad na efektivitu AI pri spracovaní veľkých dát |

| Early Detection of Spam Domains with Passive DNS and SPF | Fernandez, S et al., 2022 | [7](https://www.webofscience.com/wos/woscc/full-record/WOS:000787796800002) | Pasívne DNS + SPF analýza | Farsight Security, TXT records | Detekcia spam domén, nízka FPR | Len SPF, abstrakt | Priama aplikácia pasívneho auditu, využitie SPF |

| Malicious Domain Name Detection Using ML Algorithms | Alshehri, L et al., 2025 | [8](https://www.webofscience.com/wos/woscc/full-record/WOS:001485893300001) | XGBoost, LightGBM, CatBoost | 90k domén | Vysoká presnosť, nízke nároky | Len DNS, absencia email/TLS | Relevantné pre výber AI modelu a metriky |

| Practical Real-time Detection of IPv4 Record Classical Domain Hijacking at Scale | Szurdi, J et al., 2026 | [9](https://www.webofscience.com/wos/woscc/full-record/WOS:001866420300079) | Pasívne DNS + aktívne merania | 100+ TB pasívnych DNS logov | Detekcia hijackingu v reálnom čase | Potreba veľkých dát | Dôležitý pre validáciu pasívnych metód |

| The Persistent Threat of DGA-Domains Used by Botnets | Drichel, A et al., 2025 | [10](https://www.webofscience.com/wos/woscc/full-record/WOS:001701698100033) | Merania + ML | Zóny 1165 TLD | Detekcia 7058 mal. domén, ML objavuje nové DGA | Len DNS | Podpora proaktívnej detekcie ML |

| Fast-Flux Dataset: Enhancing Cybersecurity Analysis and Defense | Shatnawi, AS et al., 2026 | [11](https://www.webofscience.com/wos/woscc/full-record/WOS:001892593900001) | Dataset, ML baseline | 67k fast-flux domén | 96% presnosť detekcie | Dataset, nie metóda | Benchmark pre tréning/validáciu modelov |

Poznámka: Pri niektorých článkoch je prístup len k abstraktu – podrobnosti nevyvodzujem mimo dostupných informácií.

Tematická syntéza a odpovede na otázky

1. **Metódy hodnotenia bezpečnosti z verejných údajov:**

Pasívne metódy využívajú DNS záznamy, emailové autentifikačné mechanizmy (SPF, DKIM, DMARC), SSL/TLS konfigurácie a HTTP bezpečnostné hlavičky získané z verejne dostupných zdrojov (napr. pasívne DNS, Farsight, Certificate Transparency). Ich hlavnou výhodou je neinvazívnosť, nevytvárajú riziko detekcie cieľom ani právny spor. Obmedzením je, že absencia záznamu nemusí znamenať zraniteľnosť a niektoré stavy (napr. chýbajúca CSP alebo DMARC) môžu byť legitímne [Fernandez et al., 2022; Szurdi et al., 2026].

2. **Spoľahlivá identifikácia a falošné poplachy:**

Spoľahlivo možno identifikovať syntaktické chyby v DNS, nesprávne SPF/DKIM/DMARC, slabé TLS konfigurácie a absenciu základných HTTP hlavičiek (HSTS, CSP). Falošné poplachy vznikajú najmä pri doménach v testovacej prevádzke, zastaralých alebo vedľajších doménach, a pri dynamických konfiguráciách [Fernandez et al., 2022; Arkadopoulou et al., 2026; Alshehri et al., 2025].

3. **AI a strojové učenie vs pravidlové metódy:**

ML modely (CNN, Transformer, AutoEncoder, XGBoost) demonštrujú vyššiu presnosť a lepšiu adaptabilitu na nové typy útokov než pravidlové systémy, najmä pri detekcii DGA domén, fast-flux, a spam domén. Pravidlové metódy sú jednoducho interpretovateľné, ale náchylné na falošné poplachy a horšiu detekciu neznámych hrozieb [Zhang et al., 2025; Arkadopoulou et al., 2026; Alshehri et al., 2025; Yang et al., 2026].

4. **Stanovenie a overovanie skóre spoľahlivosti:**

Spoľahlivosť sa stanovuje buď heuristicky (napr. počet zdrojov, prítomnosť viacerých chýb) alebo pomocou kalibrácie výstupu AI modelu (probabilistické skóre, SHAP analýza, F1-score). Overovanie spočíva v testovaní na oddelených dátach a porovnávaní s manuálne overenými incidentmi [Arkadopoulou et al., 2026].

5. **Výskumné medzery a experiment pre LANCE:**

Chýba komplexný systém, ktorý by spájal viacero technológií (DNS, email, TLS, HTTP) s AI filtráciou a zároveň kalibroval spoľahlivosť výstupov podľa reálnych podmienok v európskom/regulovanom kontexte. LANCE môže túto medzeru vyplniť validáciou na rozsiahlom datasete firemných domén, porovnaním pravidlovej a AI metódy, oddelením tréningových a testovacích dát, a meraním precision, recall, FPR (FP/(FP+TN)) a chybovosti upozornení (FP/(TP+FP)). Pre cieľ pod 10 % je relevantná metrika FP/(TP+FP), keďže zodpovedá podielu chybných upozornení voči všetkým alertom.

Návrh validácie prototypu

• Zozbieranie referenčných nálezov z pasívnych údajov (DNS, SPF, DKIM, DMARC, TLS, HTTP hlavičky) pre vzorku domén.

• Paralelné vyhodnotenie pravidlovou a AI metódou, oddelenie tréningovej a testovacej množiny.

• Meranie metrik: precision, recall, FPR (FP/(FP+TN)), podiel chybných upozornení (FP/(TP+FP)).

• Sledovať, či podiel chybných upozornení (FP/(TP+FP)) neklesne pod 10 %, čo je cieľ projektu, pričom FPR (FP/(FP+TN)) ukazuje podiel falošných poplachov voči všetkým negatívnym prípadom (vhodné pre celkovú robustnosť).

Zoznam použitých zdrojov

• Masri, R et al., 2025, WOS:001580797700001

• Zhang, WY et al., 2025, WOS:001588384600002

• Arkadopoulou, E et al., 2026, WOS:001754887400040

• Kollanur, B et al., 2024, WOS:001482964300032

• Yang, DS et al., 2026, WOS:001882330100023

• Vanerio, J et al., 2023, WOS:001148155800008

• Fernandez, S et al., 2022, WOS:000787796800002

• Alshehri, L et al., 2025, WOS:001485893300001

• Szurdi, J et al., 2026, WOS:001866420300079

• Drichel, A et al., 2025, WOS:001701698100033

• Shatnawi, AS et al., 2026, WOS:001892593900001

Opis vyhľadávacej stratégie:

Dňa 2026-10-13 bola v databáze Web of Science vykonaná systematická rešerš s využitím anglických kľúčových slov: “passive security assessment”, “external attack surface management”, “DNS security”, “SPF”, “DKIM”, “DMARC”, “TLS configuration”, “HTTP security headers”, “false positive reduction”, “machine learning”, “confidence calibration”, “NIS2”, filtrovaná na roky 2020–2026. Zaradené boli aj staršie zásadné práce, ak boli pre daný okruh relevantné.

Záver:

Projekt LANCE reaguje na aktuálne výzvy v pasívnom audite bezpečnosti firemných domén a ponúka inovatívne spojenie AI filtrácie s cieľom zníženia falošných poplachov pod 10 %. Výskum ukazuje, že kombinácia pasívnych technických kontrol a strojového učenia poskytuje robustnejší základ pre spoľahlivé hodnotenie rizík, pričom experimentálne overenie na oddelených dátach a presne definované metriky sú kľúčové pre vedecké uznanie výsledkov.

Chcete rozšíriť prehľad o vizualizácie vývoja témy, analýzu najčastejších autorov alebo krajín, alebo vyhľadať ďalšie pramene podľa špecifickej technológie či oblasti?

View 11 referenced documents

1. A Redundant Array of Independent Disks (RAID)-Inspired Framework for Robust Domain Name System (DNS) Security: Mitigating Distributed Denial-of-Service (DDoS) Attacks Through Distributed Data Encoding and Redundancy
Masri, R; Alouneh, S; Shawar, B
2025 | SECURITY AND PRIVACY

CITATION NETWORK
0 Citations 25 References

2. ITransformer_CNN: a malicious DNS detection method with flexible feature extraction
Zhang, W; Chen, W; Wu, L
2025 | PEER-TO-PEER NETWORKING AND APPLICATIONS

CITATION NETWORK
0 Citations 32 References

3. Feature Engineering in Unsupervised DNS Botnet Detectors Based on eXplainable AI
Arkadopoulou, E; Kostopoulos, N; Maglaris, V
2026 | IEEE ACCESS

CITATION NETWORK
0 Citations 52 References

4. DCPsolver: Enhancing DNS Cache Poisoning Defenses with Resolver-Based SmartNICs
Kollanur, B; Friday, K; Bou-Harb, E
2024 | 2024 22ND INTERNATIONAL SYMPOSIUM ON NETWORK COMPUTING AND APPLICATIONS, NCA

CITATION NETWORK
0 Citations 34 References

5. Too Open to be Secure: An Evaluation of OpenNIC DNS Services and Domains
Yang, D; Liang, X; Gao, X
2026 | 2026 56TH ANNUAL IEEE INTERNATIONAL CONFERENCE ON DEPENDABLE SYSTEMS AND NETWORKS, DSN

CITATION NETWORK
0 Citations 107 References

6. Poster: P4DME: DNS Threat Mitigation with P4 In-Network Machine Learning Offload
Vanerio, J; Gyoergyi, C; Schmid, S
2023 | PROCEEDINGS OF THE 6TH EUROPEAN P4 WORKSHOP, EUROP4 2023

CITATION NETWORK
1 Citations 41 References

7. Early Detection of Spam Domains with Passive DNS and SPF
Fernandez, S; Korczynski, M; Duda, A
2022 | PASSIVE AND ACTIVE MEASUREMENT (PAM 2022)

CITATION NETWORK
6 Citations 35 References

8. Malicious Domain Name Detection Using ML Algorithms
Alshehri, L; Alajmani, S
2025 | INTERNATIONAL JOURNAL OF ADVANCED COMPUTER SCIENCE AND APPLICATIONS

CITATION NETWORK
0 Citations 18 References

9. Practical Real-time Detection of IPv4 Record Classical Domain Hijacking at Scale
Szurdi, J; Ghasemisharif, M; Liu, D
2026 | PROCEEDINGS OF THE TWENTY-FIRST ACM ASIA CONFERENCE ON COMPUTER AND COMMUNICATIONS SECURITY, ASIA CCS 2026

CITATION NETWORK
0 Citations 80 References

10. The Persistent Threat of DGA-Domains Used by Botnets
Drichel, A; Meyer, U

CITATION NETWORK
0 98

2025 | 2025 28TH INTERNATIONAL SYMPOSIUM ON RESEARCH IN ATTACKS, INTRUSIONS AND DEFENSES, RAID

Citations References

11. Fast-Flux Dataset: Enhancing Cybersecurity Analysis and Defense

Shatnawi, A; Al-Duwairi, B; Almazari, M

2026 | DATA

CITATION NETWORK

0 Citations 29 References

This service uses artificial intelligence (AI). Certain outputs are generated by AI and are provided on an "as is" basis. AI-generated outputs may contain errors, inaccuracies, or omissions and should be independently reviewed and verified before use. Use of this service is governed by the Clarivate Terms of Business.